


Modul 1

Grundlagen Datenmodellierung und Datenbanksysteme

Julian-Paul Haslinger



Drei Fragen für heute

- **Warum reicht eine Datei nicht immer?**
- **Was übernimmt ein DBMS?**
- **Warum müssen wir Daten modellieren?**

Einführung



- "Ein **Datenbanksystem** (DBS) ist ein **System** zur **elektronischen Datenverwaltung**." [Wikipedia]
- **Elektronische Daten** sollen u.a.
 - **erfasst, verändert, gelöscht**
 - wieder **erlangt** (analysiert) und
 - dauerhaft **gespeichert** (persistiert) werden können.

ABER: das könnte man doch auch mit **Dateien** realisieren, oder?!

ACTIVITY: Dann nehmen wir eben CSV

```
customer_id;customer_name;city;order_id;product;price
17;Mayer GmbH;Linz;4711;Sensor A;29.90
17;Maier GmbH;Linz;4712;Sensor B;19.90
17;Mayer GmbH;Wien;4713;Sensor A;29.90
23;Huber KG;Graz;4714;Sensor C;
23;Huber KG;Graz;4715;Sensor A;29.90
```


- **Diese Datei ist die zentrale Datenhaltung eines produktiven Systems.**
- **3 Minuten, zu zweit**
 - Welche Werte sind auffällig? Welche Fachregel benötigen Sie, um einen Fehler nachzuweisen?
 - Welche weiteren Probleme entstehen vermutlich bei mehreren Anwendungen/Benutzern?
 - Welche Regeln würden Sie gerne technisch erzwingen?

Was müssten unsere Anwendungen selbst lösen?

Aufgabe	Beispiel
Regeln prüfen	Eine benötigte Kennung fehlt oder ein Wert liegt außerhalb des erlaubten Bereichs.
Änderungen koordinieren	Zwei Anwendungen ändern denselben Datenbestand.
Daten nach Fehlern wiederherstellen	Ein bestätigter Datenstand soll einen Systemausfall überstehen.
Zugriff begrenzen	Ein Konto darf lesen, aber keine Daten ändern.


Viele dieser Aufgaben sind unabhängig von der konkreten Anwendung.

DB ≠ DBMS ≠ DBS




Was übernimmt ein DBMS?

Unsere Landkarte



Ein Mechanismus kann mehrere Ziele unterstützen. Für korrekte Daten benötigen wir sowohl passende Regeln als auch passende Abläufe.

Die Anwendung soll nicht alles wissen müssen



- **Logische Datenunabhängigkeit**
 - Anwendungen sollen begrenzt von Schemaänderungen entkoppelt sein.
 - Eine Sicht kann eine stabile Schnittstelle bereitstellen; nicht jede Schemaänderung bleibt für Anwendungen folgenlos.
- **Physische Datenunabhängigkeit**
 - Anwendungen sollen Speicher- und Zugriffspfadetails nicht kennen.
 - Beispiel: Ein Index kann sich ändern, während dieselbe Abfrage gültig bleibt.

Historische Entwicklung: Relationale DBS

■ 1970: Relationales Modell

- Edgar F. Codd veröffentlicht das relationale Datenmodell bei IBM.
- Daten werden logisch als **Relationen** beschrieben.

■ 1970er: Relationale DBMS werden praktisch

- **IBM System R**: Forschungsprojekt zur Umsetzung des relationalen Modells
 - Entwicklung von **SEQUEL** → **SQL**
 - wichtiger Vorläufer von **IBM DB2**
- **UC Berkeley INGRES**: zweiter wichtiger Forschungsstrang
 - eigene Anfragesprache **QUEL**

Codd liefert das Modell.
System R prägt SQL.
INGRES führt zu POSTGRES.
POSTGRES führt zu
PostgreSQL.

■ 1980er: POSTGRES

- Michael Stonebraker und Team entwickeln an der UC Berkeley **POSTGRES** = „**POST-Ingres**“
- Ziel: relationales Modell um neue Datentypen und erweiterbare DBMS-Konzepte ergänzen

■ 1990er: PostgreSQL

- 1994/95: POSTGRES erhält SQL-Unterstützung → **Postgres95**
- 1996: Umbenennung zu **PostgreSQL**
- heutiger Open-Source-Nachfolger der Berkeley-Linie ([info](#)).

PREDICT: Eine Information, drei Kopien


customer_id	customer_name	city	order_id
17	Mayer GmbH	Linz	4711
17	Mayer GmbH	Linz	4712
17	Mayer GmbH	Linz	4713

- Für dieses Beispiel gilt:
 - **city** speichert den aktuellen Hauptsitz des Kunden.
 - Pro **customer_id** gibt es genau einen aktuellen Hauptsitz.
- **Welche Zustände können entstehen, wenn nicht alle drei Stellen gemeinsam aktualisiert werden?**

Ein DBMS kann Regeln durchsetzen.

Aber woher kommen die Regeln?

Aus der Fachsemantik.



Nicht direkt von der Fachidee zu ‘CREATE TABLE’

Anhang I: Definitionen

Datenbanksystem (DBS)

DBMS und die von ihm verwaltete Datenbasis

Datenbankverwaltungssystem (DBMS)

Software zur Definition, Verwaltung und kontrollierten Nutzung von Datenbanken.

Datenbank (DB)

Organisierter Datenbestand

Systemkatalog

Gespeicherte Metadaten, beispielsweise über Tabellen, Spalten und Constraints.

Anhang II: Definitionen

Datenmodell

Ein Datenmodell stellt Konzepte bereit, mit denen wir Datenstrukturen, Beziehungen, zulässige Operationen und Integritätsregeln beschreiben. Ein konkretes Schema verwendet diese Konzepte für eine Miniwelt. Im relationalen Modell arbeiten wir mit Relationen, Attributen und Regeln. SQL ist eine Sprache, mit der wir ein relationales Schema definieren und Daten abfragen oder ändern.

Anhang III: Definitionen

Datenbankschema (Intension)

Ein Datenbankschema legt die Struktur der Daten fest. (Metadaten: Daten über Datenbank)

Beispiel

Jeder Sensor besitzt eine eindeutige `sensor_id` und eine Bezeichnung.

Datenbankausprägung (Extension)

Die Datenbankausprägung stellt den momentan gültigen Zustand der Datenbank dar.

Beispiel

Aktuell sind S-4711 „FH2, HS2“ und S-4712 „FH3, HS7“ gespeichert. Ein neuer Sensor ändert den Datenzustand. Eine neue verpflichtende Eigenschaft ändert das Schema.

Anhang IV: Definitionen

Redundanz

Redundanz ist das mehrfache Vorhandensein ein und derselben Information. Redundanz ist nicht automatisch fehlerhaft; kritisch ist unkontrollierte Mehrfachspeicherung desselben fachlichen Fakts.

Konsistenz

Konsistenz bezeichnet in der Informatik allgemein die Widerspruchsfreiheit von Daten.

Datenintegrität

Unter Datenintegrität versteht man die logische Korrektheit, Gültigkeit und Genauigkeit von Daten in einer Datenbank.

Anhang V: Definitionen

Entwurfsanomalien

Ein Schema kann voneinander unabhängige Fakten so koppeln, dass Änderungen zusätzliche Arbeit oder unerwünschten Informationsverlust verursachen. Das DBMS kann dabei seine definierten Regeln korrekt einhalten.

Ändern

Der aktuelle Hauptsitz eines Kunden steht in mehreren Bestellzeilen. Bei einem Umzug müssen alle Kopien konsistent geändert werden.

Einfügen

In einer reinen Bestellliste mit verpflichtender Bestellnummer lässt sich ein neuer Kunde ohne Bestellung nicht eigenständig speichern.

Löschen

Wird die letzte Bestellzeile eines Kunden gelöscht, verschwinden auch dessen nur dort gespeicherte Stammdaten.